

人工知能特論

#08 解釈可能性の基礎

米澤 弘毅

シチュエーション

ある医療機関
診断

サンプル



医師




診断結果




シチュエーション

ある医療機関
将来像

サンプル



AI



予測結果

95%陰性


50%陰性

医師



シチュエーション


“普通”構築されるAI



シチュエーション

問題点

データ漏洩 (data leakage)



本番では存在しなかったらどうする!?

シチュエーション

問題点

バイアス

ある人/グループが優遇されるような不公平な予測

特にサンプリングバイアスに注意

一般データ保護規則 (GDPR)


モデルが判断した理由について解釈/説明する必要あり

コンセプトドリフト

データの傾向が変わった時に対応しきれない

シチュエーション

堅牢なAI



ホワイトボックスモデル

入出力の関係がわかりやすい予測モデル

線形回帰 ロジスティック回帰

決定木 GAM etc.

今回想定している例

糖尿病の進行度判定

