

人工知能特論

#13 物性値予測

米澤 弘毅

物性値

様々な尺度で測った物質の性質

密度	比熱	粘度	臨界温度	結合親和性
臨界圧力	臨界容積	蒸気圧	蒸発熱	
融解熱	熱伝導度	表面張力	拡散係数	

物性値予測問題

教師あり学習の典型例

分子の情報 x }
物性値 y }  物性値の予測値 $\hat{y}$ を計算するモデル

訓練データ $\mathcal{D} = \left\{ \left(\begin{array}{c} \text{分子の情報} \\ x_n \end{array}, \begin{array}{c} \text{物性値} \\ y_n \end{array} \right) \right\}_{n=1}^N$

目標となる予測器 $y_n \approx \hat{y}(x_n)$

教師あり学習 (supervised learning)

定式化のための仮定(1)

入出力の対が従う確率分布が存在

$$p_{X,Y} \in \Delta(\mathcal{X} \times \mathcal{Y})$$

統計手法を用いて定式化

定式化のための仮定(2)

訓練データに含まれる事例 (x_n, y_n) が分布 $p_{X,Y}$ に独立に従う

$$\mathcal{D} \stackrel{\text{i.i.d.}}{\sim} p_{X,Y}$$

教師あり学習

学習の定式化

訓練データ $\mathcal{D} \stackrel{\text{i.i.d.}}{\sim} p_{X,Y}$

未知の入力 $x \sim p_X$ に対応する出力 $y \sim p_Y(\cdot|x)$ を

「うまく」予測できる予測器 $\hat{y}: \mathcal{X} \rightarrow \mathcal{Y}$ を作成

パラメトリックな条件付き確率分布 $p_\theta(y|x)$ = 予測分布
パラメタ $\theta \in \Theta$

予測分布を $p_{Y|X}(y|x)$ に近づけるように

決定的な予測器 $\hat{y}(x) \in \arg \max_{y \in \mathcal{Y}} p_\theta(y|x)$

予測分布の学習

予測の良さの定量化

カルバック・ライブラー情報量 (KL divergence)

予測分布から得られる $\mathcal{X} \times \mathcal{Y}$ 上の分布 $p_\theta(y|x)p_X(x)$

 近さを測定

真の分布 $p_{X,Y}(x,y)$

$$\begin{aligned}\text{KL}(p_{X,Y} \| p_X p_\theta) &= \mathbb{E}_{(X,Y) \sim p_{X,Y}} \left[\log \frac{p_{X,Y}(X,Y)}{p_\theta(Y|X)p_X(X)} \right] \\ &= \mathbb{E}_{(X,Y) \sim p_{X,Y}} \left[\log \frac{p_{Y|X}(Y|X)}{p_\theta(Y|X)} \right]\end{aligned}$$

KL Divergence

最適なパラメタの計算

θ に関する項のみを抽出

$$L(\theta) = \mathbb{E}_{(X,Y) \sim p_{X,Y}} \left[-\log p_{\theta}(Y|X) \right] = \text{期待損失/リスク}$$

教師あり学習

期待損失を用いた定義

データの従う分布 $p_{X,Y} \in \Delta(\mathcal{X} \times \mathcal{Y})$

予測分布の集合 $\{p_\theta(y|x) | \theta \in \Theta\}$

訓練データ $\mathcal{D} \overset{\text{i.i.d.}}{\sim} p_{X,Y}$

求めるパラメタ $\theta^* \in \arg \min_{\theta \in \Theta} L(\theta)$

経験損失最小化に基づく教師あり学習

経験損失 (empirical loss)

期待損失をサンプル平均で近似


$$\begin{aligned}\mathbb{E}_{(X,Y) \sim p_{X,Y}} \left[-\log p_{\theta}(Y|X) \right] &\approx \hat{\mathbb{E}}_{(X,Y) \sim \mathcal{D}} \left[-\log p_{\theta}(Y|X) \right] \\ &= \frac{1}{|\mathcal{D}|} \sum_{(x,y) \in \mathcal{D}} \left[-\log p_{\theta}(Y|X) \right] \quad (= L(\theta; \mathcal{D}))\end{aligned}$$

経験損失最小化

$$\hat{\theta} \in \arg \min_{\theta \in \Theta} L(\theta; \mathcal{D})$$

予測分布

全体の構成



関数近似器 (function approximator)

$$g_{\theta} : \mathcal{X} \rightarrow \mathbb{R}^C$$

予測器

$$p_{\theta}(y|x) = \bar{p}(y|\sigma(g_{\theta}(x)))$$

活性化関数 (activation function)

$$\sigma : \mathbb{R}^C \rightarrow \bar{\mathcal{Y}}$$

条件付き確率分布 (conditional probability distribution)

$$\bar{p}(y|\bar{y}) \quad \bar{y} \in \bar{\mathcal{Y}}$$

予測分布

損失関数 (loss function)

経験損失

$$L(\theta; \mathcal{D}) = \hat{\mathbb{E}}_{(X,Y) \sim \mathcal{D}} \left[-\log \bar{p}(Y | \sigma(g_{\theta}(X))) \right]$$

関数近似器

ex. 線形の場合

入力空間 $\mathcal{X} \subseteq \mathbb{R}^D$

パラメタ $\theta = \{\mathbf{w} \in \mathbb{R}^D, b \in \mathbb{R}\}$

$$g_{\theta}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

以降では非線形な関数近似器で最も一般的なNNを使用

予測分布

活性化関数

実数値ラベル

$\mathcal{Y} = \mathbb{R}$ のときは恒等関数 $\sigma(z) = z$ を使用

2値ラベル

$\mathcal{Y} = \{0, 1\}$ のときはシグモイド関数 $\sigma(z) = \frac{1}{1 + e^{-z}}$ を使用

多値ラベル

$\mathcal{Y} = \{0, 1, \dots, C-1\}$ のときは $\sigma_c(z) = \frac{e^{z_c}}{\sum_{c=0}^{C-1} e^{z_c}}$ として

softmax関数 $\boldsymbol{\sigma}(\mathbf{z}) = [\sigma_0(\mathbf{z}) \quad \sigma_1(\mathbf{z}) \quad \cdots \quad \sigma_{C-1}(\mathbf{z})]^T$ を使用

予測分布

条件付き確率分布

実数値ラベル

$\mathcal{Y} = \mathbb{R}$ のとき $\bar{\mathcal{Y}} = \mathcal{Y}$ として

$\bar{p}(y|\bar{y}) = \mathcal{N}(y; \bar{y}, 1)$ を多々使用

経験損失関数

$$L(\theta; \mathcal{D}) = \hat{\mathbb{E}}_{(X,Y) \sim \mathcal{D}} \left[\frac{1}{2} (Y - f_{\theta}(X))^2 \right]$$

平均二乗損失
(MSE loss)

予測分布

条件付き確率分布

2値ラベル

$\mathcal{Y} = \{0, 1\}$ のとき $\bar{\mathcal{Y}} = [0, 1]$ として

$$\bar{p}(y|\bar{y}) = \text{Bernoulli}(y; \bar{y})$$

経験損失関数

$$L(\theta; \mathcal{D}) = \hat{\mathbb{E}}_{(X, Y) \sim \mathcal{D}} \left[-Y \log f_{\theta}(X) - (1 - Y) \log (1 - f_{\theta}(X)) \right]$$

2値交差エントロピー損失
(BCE loss)



予測分布

条件付き確率分布

多値ラベル

$\mathcal{Y} = \{0, 1, \dots, C-1\}$ のとき $\bar{\mathcal{Y}} = \Delta^C$ として

$$\bar{p}(y|\bar{y}) = \text{Cat}(y; \bar{y})$$

カテゴリーカル分布

経験損失関数

$$L(\theta; \mathcal{D}) = \hat{\mathbb{E}}_{(X, Y) \sim \mathcal{D}} \left[-\mathbf{1}_Y \cdot \log \mathbf{f}_\theta(X) \right]$$

交差エントロピー損失



ニューラルネットワーク

順伝播型ニューラルネットワーク

パラメタ $W \in \mathbb{R}^{D_{out} \times D_{in}}$ $\mathbf{b} \in \mathbb{R}^{D_{out}}$

活性化関数 $\sigma(\cdot)$

ニューラルネットワーク $g(\mathbf{x}; w, \mathbf{b}) = \sigma(W\mathbf{x} + \mathbf{b})$

これを複数直列接続

よく使用される活性化関数の例

ReLU $\text{ReLU}(x) = \begin{cases} x & (x > 0) \\ 0 & (x \leq 0) \end{cases}$

tanh $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$

ニューラルネットワーク

順伝播型ニューラルネットワーク 直前の出力の次元=直後の入力次元

入出力の次元が整合的な非線形関数

$$g_{\ell} : \mathbb{R}^{D_{\ell}} \rightarrow \mathbb{R}^{D_{\ell+1}} \quad (\ell = 0, 1, \dots, L-1)$$

順伝播型ニューラルネットワークの定式化

$$g_{0:\ell} = g_{L-1} \circ g_{L-2} \circ \dots \circ g_0$$

$$\text{パラメタ} \quad W_{0:L} = \{W_{\ell}\}_{\ell=0}^{L-1} \quad \mathbf{b}_{0:L} = \{\mathbf{b}_{\ell}\}_{\ell=0}^{L-1}$$

最適化アルゴリズム

経験損失最適化問題

非線形関数にNNを用いた場合は勾配法を利用

パラメタ $\theta \in \Theta$ の範囲内での動かし方

$$\theta \leftarrow \theta - \underbrace{\alpha}_{\text{学習率}} \frac{\partial L(\theta; \mathcal{D})}{\partial \theta}$$

最適解

$$\theta^* = \arg \min_{\theta \in \Theta} L(\theta; \mathcal{D})$$

最適化アルゴリズム

誤差逆伝播法 (back propagation)

NNの層の数 L

入力 $\mathbf{x} \in \mathbb{R}^D$ 出力 $y \in \mathbb{R}$

ℓ 層目の入力 $\mathbf{z}_\ell \in \mathbb{R}^{D_\ell}$ ℓ 層目の出力 $\mathbf{z}_{\ell+1} \in \mathbb{R}^{D_{\ell+1}}$

$$\mathbf{z}_0 = \mathbf{x} \quad \mathbf{z}_L = y$$

ℓ 層目の非線形関数

$$\mathbf{u}_\ell = W_\ell \mathbf{z}_\ell$$

パラメタ $W_\ell \in \mathbb{R}^{D_\ell \times D_{\ell+1}}$

$$\mathbf{z}_{\ell+1} = \sigma_\ell(\mathbf{u}_\ell)$$

活性化関数

最適化アルゴリズム

誤差逆伝播法

1サンプルあたりの損失関数

$$\ell(W; \mathbf{x}, y) = \frac{1}{2} (y - f(\mathbf{x}; W))^2$$

ℓ 層目のパラメタの (i, j) 成分 $W_{\ell ij}$ に対する勾配

$$\frac{\partial \ell(W; \mathbf{x}, y)}{\partial W_{\ell ij}} = \frac{\partial \ell(W; \mathbf{x}, y)}{\partial \mathbf{u}_{\ell}^T} \frac{\partial \mathbf{u}_{\ell}^T}{\partial W_{\ell ij}} = \frac{\partial \ell(W; \mathbf{x}, y)}{\partial u_{\ell i}} \boxed{\frac{\partial u_{\ell i}}{\partial W_{\ell ij}}}$$

$$\mathbf{u}_{\ell} = W_{\ell} \mathbf{z}_{\ell} \longrightarrow \frac{\partial u_{\ell i}}{\partial W_{\ell ij}} = z_{\ell j}$$

最適化アルゴリズム

誤差逆伝播法

ℓ 層目のパラメタの (i, j) 成分 $W_{\ell ij}$ に対する勾配

$$\frac{\partial \ell(W; \mathbf{x}, y)}{\partial W_{\ell ij}} = \frac{\partial \ell(W; \mathbf{x}, y)}{\partial \mathbf{u}_{\ell}^T} \frac{\partial \mathbf{u}_{\ell}^T}{\partial W_{\ell ij}} = \boxed{\frac{\partial \ell(W; \mathbf{x}, y)}{\partial u_{\ell i}}} \frac{\partial u_{\ell i}}{\partial W_{\ell ij}}$$

$$\frac{\partial \ell(W; \mathbf{x}, y)}{\partial u_{\ell i}} = \frac{\partial \ell(W; \mathbf{x}, y)}{\partial \mathbf{u}_{\ell+1}^T} \boxed{\frac{\partial \mathbf{u}_{\ell+1}^T}{\partial u_{\ell i}}}$$

W_{ℓ} の i 列目

$$\mathbf{u}_{\ell+1} = W_{\ell+1} \mathbf{z}_{\ell+1} = W_{\ell+1} \sigma_{\ell}(\mathbf{u}_{\ell})$$

$$\Rightarrow \frac{\partial \mathbf{u}_{\ell+1}^T}{\partial u_{\ell i}} = W_{\ell+1, :, i} \frac{d}{du_{\ell i}} \sigma(u_{\ell i})$$

最適化アルゴリズム

誤差逆伝播法

ℓ 層目のパラメタの (i, j) 成分 $W_{\ell ij}$ に対する勾配

$$\frac{\partial \ell(W; \mathbf{x}, y)}{\partial W_{\ell ij}} = \frac{\partial \ell(W; \mathbf{x}, y)}{\partial \mathbf{u}_{\ell}^T} \frac{\partial \mathbf{u}_{\ell}^T}{\partial W_{\ell ij}} = \boxed{\frac{\partial \ell(W; \mathbf{x}, y)}{\partial u_{\ell i}}} \frac{\partial u_{\ell i}}{\partial W_{\ell ij}}$$

$$\frac{\partial \ell(W; \mathbf{x}, y)}{\partial u_{\ell i}} = \boxed{\frac{\partial \ell(W; \mathbf{x}, y)}{\partial \mathbf{u}_{\ell+1}^T}} \frac{\partial \mathbf{u}_{\ell+1}^T}{\partial u_{\ell i}}$$

$$\frac{\partial \ell(W; \mathbf{x}, y)}{\partial u_{\ell i}} \text{ の } \ell+1 \text{ 層目の値}$$

→ 出力層の勾配 $\frac{\partial \ell(W; \mathbf{x}, y)}{\partial \mathbf{u}_{L-1}^T}$ から漸化式を逆方向に計算

最適化アルゴリズム

最急降下法 (gradient descent)

$$\hat{\theta} \in \arg \min_{\theta \in \Theta} L(\theta; \mathcal{D})$$

初期値 $\theta^{(0)} \in \Theta$

学習率 $\alpha_k \in \mathbb{R}_{>0}$

$$\theta^{(k+1)} = \theta^{(k)} - \alpha_k \frac{\partial L(\theta^{(k)}; \mathcal{D})}{\partial \theta} \quad k = 0, 1, \dots, K-1$$

$$\frac{\partial L(\theta; \mathcal{D})}{\partial \theta} = \frac{1}{|\mathcal{D}|} \sum_{(x,y) \in \mathcal{D}} \frac{\partial \ell(\theta; x, y)}{\partial \theta} \text{ を毎回計算する必要あり}$$

経験損失を $O(1/|\mathcal{D}|)$ まで低下させる計算時間 $O(|\mathcal{D}| \log |\mathcal{D}|)$

最適化アルゴリズム

確率的勾配降下法 (stochastic gradient descent; SGD)

$$\hat{\theta} \in \arg \min_{\theta \in \Theta} L(\theta; \mathcal{D})$$

初期値 $\theta^{(0)} \in \Theta$ ランダムに取ったサンプル $(X, Y) \sim \mathcal{D}$

$$\theta^{(k+1)} = \theta^{(k)} - \alpha_k \frac{\partial L(\theta; X, Y)}{\partial \theta} \quad k = 0, 1, \dots, K-1$$

不偏推定量

$$\mathbb{E}_{(X, Y) \sim \mathcal{D}} \left[\frac{\partial L(\theta; X, Y)}{\partial \theta} \right] = \frac{1}{|\mathcal{D}|} \sum_{(X, Y) \in \mathcal{D}} \frac{\partial \ell(\theta; x, y)}{\partial \theta} = \frac{\partial L(\theta; \mathcal{D})}{\partial \theta}$$

最適化アルゴリズム

ミニバッチ勾配降下法 (mini-batch gradient descent)

複数のデータを用いて勾配推定の精度向上を意図

サイズ B のミニバッチを用いると

勾配の推定量の標準偏差を $1/\sqrt{B}$ 倍に

GPUで並列計算すれば計算時間の増加もある程度抑制可能

通常のミニバッチのサイズ

$$B = 10^1 \text{ or } 10^2$$

最適化アルゴリズム

学習率の決定

$$\theta^{(k+1)} = \theta^{(k)} - \boxed{\alpha_k} \frac{\partial L(\theta; X, Y)}{\partial \theta}$$

AdaGrad [Duchi et al., 2011]の場合

それまでに用いた勾配の累積2乗和

RMSProp [Hinton et al., 2012]の場合

過去の勾配の2乗の移動平均を累積

Adam [Diederik et al., 2013]の場合

モメンタム(momentum)とAdaGradを組み合わせ
パラメタの更新に”慣性力”をかける

評価

評価指標

予測分布 $p_{\hat{\theta}}$ 真の確率分布 $p_{X,Y}$

➡ 実数値の関数 $J(p_{\hat{\theta}}, p_{X,Y})$

予測器 $\hat{y}$ 真の確率分布 $p_{X,Y}$

➡ 実数値の関数 $J(\hat{y}, p_{X,Y})$

評価

目的変数が実数値でも2値でも多値でも使える評価指標

期待損失

$$J_{\text{Loss}}(p_{\hat{\theta}}, p_{X,Y}) = \mathbb{E}_{(X,Y) \sim p_{X,Y}} \left[-\log p_{\hat{\theta}}(Y|X) \right]$$

評価指標の値の解釈が微妙

評価

目的変数が実数値のときに使える評価指標

平均2乗誤差 (mean squared error; MSE)

$$J_{\text{MSE}}(\hat{y}, p_{X,Y}) = \mathbb{E}_{(X,Y) \sim p_{X,Y}} \left[(Y - \hat{y}(X))^2 \right]$$

平均平方2乗誤差 (root-mean-squared error; RMSE)

$$J_{\text{RMSE}}(\hat{y}, p_{X,Y}) = \sqrt{\mathbb{E}_{(X,Y) \sim p_{X,Y}} \left[(Y - \hat{y}(X))^2 \right]}$$

平均絶対誤差 (mean absolute error; MAE)

$$J_{\text{MAE}}(\hat{y}, p_{X,Y}) = \mathbb{E}_{(X,Y) \sim p_{X,Y}} \left[|Y - \hat{y}(X)| \right]$$

評価

目的変数が2値のときに使える評価指標

正答率 (accuracy)

$$J_{\text{Accuracy}}(\hat{y}, p_{X,Y}) = \mathbb{P}_{(X,Y) \sim p_{X,Y}} [Y = \hat{y}(X)]$$

適合率 (precision)

$$J_{\text{Precision}}(\hat{y}, p_{X,Y}) = \mathbb{P}_{(X,Y) \sim p_{X,Y}} [Y = 1 | \hat{y}(X) = 1]$$

再現率 (recall)

$$J_{\text{Recall}}(\hat{y}, p_{X,Y}) = \mathbb{P}_{(X,Y) \sim p_{X,Y}} [\hat{y}(X) = 1 | Y = 1]$$

評価

目的変数が2値のときに使える評価指標

F値 (F-measure/F1-score)

$$\frac{1}{J_{\text{F1}}(\hat{y}, p_{X,Y})} = \frac{1}{2} \left(\frac{1}{J_{\text{Precision}}(\hat{y}, p_{X,Y})} + \frac{1}{J_{\text{Recall}}(\hat{y}, p_{X,Y})} \right)$$

ROC曲線下面積 (area under the ROC curve; AUC)

ROC曲線 (receiver operating characteristic curve)

横軸: 偽陽性率 (false positive rate) 縦軸: 真陽性率 (true positive rate)

0/1を決める閾値を変更しつつROC曲線を作成

縦軸/横軸/ROC曲線/ $y=1$ で囲まれた領域の面積

$$J_{\text{AUC}}(\hat{y}, p_{X,Y}) = \mathbb{P}_{\substack{(X,Y) \sim p_{X,Y} \\ (X',Y') \sim p_{X,Y}}} \left[p_{\hat{\theta}}(X) > p_{\hat{\theta}}(X') | Y=1, Y'=0 \right]$$

評価

目的変数が多値のときに使える評価指標 $\mathcal{Y} = \{0, 1, \dots, C-1\}$

適合率 (precision)

$$J_{\text{Precision}}^{(c)}(\hat{y}, p_{X,Y}) = \mathbb{P}_{(X,Y) \sim p_{X,Y}} [Y = c | \hat{y}(X) = c]$$

再現率 (recall)

$$J_{\text{Recall}}^{(c)}(\hat{y}, p_{X,Y}) = \mathbb{P}_{(X,Y) \sim p_{X,Y}} [\hat{y}(X) = c | Y = c]$$

マクロ平均適合率 (macro-averaged precision)

$$J_{\text{Precision}}^{(M)}(\hat{y}, p_{X,Y}) = \frac{1}{|\mathcal{Y}|} \sum_{c \in \mathcal{Y}} J_{\text{Precision}}^{(c)}(\hat{y}, p_{X,Y})$$

マクロ平均再現率 (macro-averaged recall)

$$J_{\text{Recall}}^{(M)}(\hat{y}, p_{X,Y}) = \frac{1}{|\mathcal{Y}|} \sum_{c \in \mathcal{Y}} J_{\text{Recall}}^{(c)}(\hat{y}, p_{X,Y})$$

評価

目的変数が多値のときに使える評価指標 $\mathcal{Y} = \{0, 1, \dots, C-1\}$

重み付きマクロ平均 (weighted macro-average)

$$J_{\text{Precision}}^{(\text{WM})}(\hat{y}, p_{X,Y}) = \mathbb{E}_{C \sim P_Y} \left[J_{\text{Precision}}^{(C)}(\hat{y}, p_{X,Y}) \right]$$

$$J_{\text{Recall}}^{(\text{WM})}(\hat{y}, p_{X,Y}) = \mathbb{E}_{C \sim P_Y} \left[J_{\text{Recall}}^{(C)}(\hat{y}, p_{X,Y}) \right]$$

サンプルがアンバランスな場合に使用

マイクロ平均 (micro-average)

$c \in \mathcal{Y}$ か c 以外かの2値分類問題を設定

$$J_{\text{Micro}}(\hat{y}, p_{X,Y}) = \mathbb{P}_{(X,Y) \sim p_{X,Y}} [Y = \hat{y}(X)]$$

評価

評価指標の推定

プラグイン推定量 (plug-in estimator)

未知の分布 $p_{X,Y}$ を

サンプル $\mathcal{D}$ から得られる経験分布 $\hat{p}_{X,Y}(x, y; \mathcal{D})$ で代用

$$J(\hat{y}, p_{X,Y}) \approx J(\hat{y}, \hat{p}_{X,Y}(\mathcal{D}))$$

Glivenko-Cantelliの定理

ある条件下でデータを無限に増やすと

$$\hat{p}_{X,Y} \rightarrow p_{X,Y}$$

評価

評価指標の推定

プラグイン推定量 $J(\hat{y}, \hat{p}_{X,Y}(\mathcal{D}))$

1つの事例に対する評価指標 $\xi(x, y, \hat{y})$

評価指標 $J(\hat{y}, p_{X,Y}) = \mathbb{E}_{(X,Y) \sim p_{X,Y}} [\xi(X, Y, \hat{y})]$

$$\begin{aligned}\mathbb{E}_{\mathcal{D}} [J(\hat{y}, \hat{p}_{X,Y}(\mathcal{D}))] &= \mathbb{E}_{\mathcal{D}} [\mathbb{E}_{(X,Y) \sim \hat{p}_{X,Y}(\mathcal{D})} [\xi(X, Y, \hat{y})]] \\ &= \mathbb{E}_{(X,Y) \sim p_{X,Y}} [\xi(X, Y, \hat{y})] \\ &= J(\hat{y}, p_{X,Y}(\mathcal{D})) \rightarrow \text{不偏推定量}\end{aligned}$$

正答率に対するプラグイン推定量=不偏推定量

評価

サンプル再利用によるバイアス

サンプル $\mathcal{D}$ を予測器の推定&評価指標の推定の両方に用いる場合

評価指標の推定値 $J(\hat{y}, \hat{p}_{X,Y}(\mathcal{D}))$

$$\begin{aligned}\mathbb{E}_{\mathcal{D}}[J(\hat{y}, \hat{p}_{X,Y}(\mathcal{D}))] &= \mathbb{E}_{\mathcal{D}}\left[\mathbb{E}_{(X,Y) \sim \hat{p}_{X,Y}(\mathcal{D})}[\xi(X, Y, \hat{y}(\mathcal{D}))]\right] \\ &\neq \mathbb{E}_{(X,Y) \sim p_{X,Y}}[\xi(X, Y, \hat{y}(\mathcal{D}))] = J(\hat{y}(\mathcal{D}), p_{X,Y})\end{aligned}$$

不偏推定量でない


同じサンプルを使い回すと推定にバイアスが乗る

➡ 性能評価が不正確に

評価

サンプル再利用の回避

ホールドアウト法 (holdout method)



予測器の訓練 $\hat{y}(\mathcal{D}_{\text{train}})$ 経験分布 $\hat{p}_{X,Y}(\mathcal{D}_{\text{test}})$

プラグイン推定量 $J(\hat{y}(\mathcal{D}_{\text{train}}), \hat{p}_{X,Y}(\mathcal{D}_{\text{test}}))$

$$\begin{aligned} \mathbb{E}_{\mathcal{D}} \left[J(\hat{y}(\mathcal{D}_{\text{train}}), \hat{p}_{X,Y}(\mathcal{D}_{\text{test}})) \right] &= \mathbb{E}_{\mathcal{D}_{\text{test}}} \left[\mathbb{E}_{(X,Y) \sim \hat{p}_{X,Y}(\mathcal{D}_{\text{test}})} \left[\xi(X, Y, \hat{y}(\mathcal{D}_{\text{train}})) \right] \right] \\ &= \mathbb{E}_{(X,Y) \sim p_{X,Y}} \left[\xi(X, Y, \hat{y}(\mathcal{D}_{\text{train}})) \right] = J(\hat{y}(\mathcal{D}_{\text{train}}), p_{X,Y}) \end{aligned}$$


不偏推定量になった!

評価

サンプル再利用の回避

交差検証 (cross validation)

ex. 3分割交差検証



テスト性能

$\hat{p}_1$

$\hat{p}_2$

$\hat{p}_3$

評価指標の推定量 $\hat{p} = \frac{1}{K} \sum_{k=1}^K \hat{p}_k$

分割されるデータの個数

評価

サンプル再利用の回避

物性値予測問題特有のサンプル分割

仮定: 各サンプルが独立に同一分布に従う

but 物性値予測問題ではこの仮定が成り立つか怪しい



既知の分子に似たものの物性値が測定されやすい

解決法: 分子骨格 (scaffold) を用いたサンプル分割

分子の中心的な構造

分子骨格が共通した分子をグループ化

→ 新規の形状の分子構造に対する予測性能を推定可能に

評価

ハイパーパラメタ選択

ハイパーパラメタ (hyperparameter)

学習器に事前に与えるパラメタ

経験損失最小化では決定不可

ハイパーパラメタの候補集合 $\mathcal{H} = \{h_m\}_{m=1}^M$



評価

ハイパーパラメータ選択

ハイパーパラメータ h_m ($m=1,2,\dots,M$) をもつモデルそれぞれを
訓練データ $\mathcal{D}_{\text{train}}$ で訓練



それぞれのモデルを検証データ $\mathcal{D}_{\text{val}}$ で評価 評価値 $\hat{p}_m$



$$m^* = \arg \min_{m=1,2,\dots,M} \hat{p}_m$$



h_{m^*} のモデルの性能をテストデータ $\mathcal{D}_{\text{test}}$ を用いて推定

過剰適合 (overfitting)

過剰適合/過学習

経験損失を小さくできた but テストデータでは評価指標が良くない
変数が動ける範囲を広くすれば経験損失を小さくできるけども…

正則化 (regularization)

過剰適合を防ぐ方法

モデルの大きさに制限

正則化項

パラメタの大きさに比例する項を経験損失に加算

パラメタ $\mathbf{w} \in \mathbb{R}^D$ ハイパーパラメタ $\lambda > 0$

$$\ell_2 \text{ 正則化} \quad r_2(\mathbf{w}; \lambda) = \frac{\lambda}{2} \|\mathbf{w}\|_2^2$$

$$\ell_1 \text{ 正則化} \quad r_1(\mathbf{w}; \lambda) = \frac{\lambda}{2} \|\mathbf{w}\|_1$$

$\mathbf{w}$ がスパースになりがち

過剰適合への対応

学習の早期停止 (early stopping)

パラメタの値が大きくなりすぎないうちに打ち切り

訓練中に時折検証データを用いて予測性能を推定

→ 予測性能が悪化したら停止

ドロップアウト (dropout)

NNの過剰適合を防ぐ有力な方法

ハイパーパラメタ $p \in [0,1]$ $\text{Dropout}_p : \mathbb{R}^D \rightarrow \mathbb{R}^D$

$$\text{Dropout}_p(\mathbf{x})_d = \begin{cases} \frac{1}{1-p} x_d & \text{w.p. } p \\ 0 & \text{w.p. } 1-p \end{cases} \quad (d = 1, 2, \dots, D)$$

グラフニューラルネットワーク

定義

入力 $G = (V, E)$

出力 頂点 $v \in V$ に対する潜在ベクトル $\mathbf{z}_v \in \mathbb{R}^{D_z}$ 次元数

メッセージ伝達 (message passing)

GNNの内部計算を行うための操作

$$\mathbf{z}_v^{(0)} \in \mathbb{R}^{D_{z^{(0)}}}$$
$$\mathbf{z}_v^{(\ell+1)} = f\left(\mathbf{z}_v^{(\ell)}, \left\{\mathbf{z}_u^{(\ell)}\right\}_{u \in \mathcal{N}(v)}\right) \quad \ell = 0, 1, \dots, L-1$$

隣接する頂点の集合

グラフニューラルネットワーク

ニューラルグラフフィンガープリント [Duvenaud et al., 2015]

フィンガープリントを微分可能な形に拡張

ニューラルネットワーク化して得られるモデル

グラフ畳み込みネットワーク (GCN) [Kipf & Welling, 2017]

ニューラルネットワークの隠れ層にCNNを導入

MoleculeNet

物性値予測問題を集めたベンチマーク
supervised learningの精度比較用



A Benchmark for Molecular Machine Learning

A work by [Pande Group](#) at Stanford

[View it on GitHub](#)

Abstract

MoleculeNet is a benchmark specially designed for testing machine learning methods of molecular properties. As we aim to facilitate the development of molecular machine learning method, this work curates a number of dataset collections, creates a suite of software that implements many known featurizations and previously proposed algorithms. All methods and datasets are integrated as parts of the open source [DeepChem](#) package(MIT license).